

# Hierarchical quantum classifiers

Grant et al. (2018)

Apresentado por : Marcela, Israel e Caio.

# Agenda

- Introdução
- Objetivo Geral
- Objetivos Específicos
- Metodologia
- Resultados
- Discussões
- Conclusão

# Introdução

Redes Tensoriais

Redes Tensoriais com estrutura Hierárquica

## **Tipos de Redes de Tensores**

- Rede tensorial em árvore (TTN)
- Entrelaçamento de renormalização de múltipla escala ansatz (MERA)
  - Os MERAs são semelhantes aos TTNs, mas fazem uso de transformações unitárias adicionais para capturar efetivamente uma faixa mais ampla de correlações quânticas.
  - Circuito mais complexo.

# Introdução




Figura 1: Classificador TTN para 8 qubits.

# Introdução




Figura 2: Classificador MERA para 8 qubits.

# Introdução

Versões unidimensionais (1D) e bidimensionais (2D) dos circuitos TTN e MERA foram propostas na literatura.

No caso 1D, os circuitos TTN e MERA podem ser avaliados eficientemente através de técnicas clássicas quando os dados de entrada são codificados em qubit (**codificação em qubit**).

A avaliação dos circuitos TTN e MERA são provavelmente classicamente **intratáveis** quando os dados são codificados em amplitude (**codificação de amplitude**).

# Introdução

Em 2D, o circuito TTN é eficientemente simulável ao utilizar a codificação de qubit, enquanto o circuito 2D MERA não é.

Classificadores de estrutura 1D → podem ser utilizados para classificar dados sequenciais, séries temporais

Classificadores de estrutura 2D → classificar Imagens.

Como não puderam simular grandes circuitos MERA 2D, os pesquisadores restringiram os experimentos ao caso 1D.

# Objetivo Geral

Neste trabalho considera-se a aprendizagem de máquina supervisionada a fim de classificar dados clássicos e quânticos em um computador quântico utilizando circuitos quânticos hierárquicos.

## Objetivos Específicos

- Propor uma abordagem de classificador híbrido.
- Comparar os resultados obtidos por redes tensoriais MERA, TTN , Classificador híbrido e Classificador logístico.
- Utilizar o IBM Quantum Experience para testar a robustez ao ruído despolarizante.
- Implementar o modelo no computador quântico ibmqx4 .



# Metodologia

Massa de Dados utilizadas : Iris dataset, MNIST handwritten digits, e bases de dados quânticas sintéticas.




Figura 3: Fluxograma da Metodologia.

# **Metodologia : Codificação dos dados de entrada**

Para executar a classificação em um computador quântico, os dados de entrada devem ser codificados em um estado quântico.

Duas maneiras pelas quais isso pode ser alcançado são pela : codificação de qubit ou codificação de amplitude.

## **Codificação de qubit**

Codificação dos dados nas amplitudes de qubits individuais em um estado totalmente separável

## **Codificação de amplitude**

Codificação dos dados nas amplitudes de um estado emaranhado.

# Metodologia : Codificação dos dados de entrada

Utilizou-se ambos os métodos de codificação neste trabalho.

Dados Clássicos : Executaram a codificação de qubit usando rotações de qubit.  
→ Codificação de qubit.

Dados Quânticos: Assumiram que os dados chegam de outro dispositivo quântico e já são um estado codificado de amplitude emaranhado. → Codificação de amplitude.

# Metodologia : **classificar**

## **Classificador**

Uma série de operações unitárias aplicadas a um estado quântico inicial.

Em seguida, uma medição é realizada em um qubit rotulado (qubit target).

Na prática, são necessárias várias execuções para aproximar a expectativa do valor da medida com o resultado da medição em si.

O resultado mais frequente é a classe prevista.

Mais execuções aumentam a confiança do classificador.

# Metodologia : **classificar**

Considerar

- Layout do circuito hierárquico
- Algoritmo para aprender os parâmetros.
- Circuito em árvore.
- Pode ser reparametrizado com um simples conjunto de portas que é compatível com os computadores quânticos atualmente disponíveis.

# Metodologia : **Classificar**

A otimização dos circuitos pode ser realizada :

- Gradiente descendente estocástico.
- Gradiente descendente analítico.
  - Faz sentido utilizar em redes eficientemente simuláveis
- Gradiente descendente estimado numericamente através do computador quântico.
  - Para circuitos que não podem ser simulados com eficiência.
- Abordagem híbrida

# Metodologia : **Classificar**

Foi proposta uma abordagem híbrida que envolve uma etapa clássica de pré-treinamento para inicializar algumas das portas. Os pesquisadores validaram empiricamente a abordagem ao inicializar um MERA 1D com um TTN 1D pré-treinado.

Tal pré-treinamento reduz o número médio etapas de treinamentos necessárias até a convergência em um modelo com acurácia comparável, um benefício para implementações em computadores quânticos em curto prazo.

# Metodologia: Classificar




Figura 4: Três parametrizações alternativas dos blocos unitários na Fig.4.a Duas rotações arbitrárias de qubit único, seguidas por um CNOT. A direção do CNOT pode ser revertida para preservar a estrutura causal da rede. Essa configuração simples pode ser prontamente implementada em computadores quânticos disponíveis. b. Uma porta arbitrária de dois qubit. Na prática, essa configuração geral exigiria a compilação em portas dependentes de hardware de baixo nível.c. Uma porta arbitrária de três qubits envolvendo um qubit ancilla. A ancilla é traçada permitindo realizar um rico conjunto de operações não lineares. A implementação deste último no hardware atualmente disponível exigiria uma etapa de compilação.



# Metodologia: Análise dos Resultados

Demonstraram suas técnicas usando TTNs e MERAs e compararam o desempenho para várias parametrizações.

- O primeiro deles usa apenas rotações de um qubit e portas CNOT fixadas.
- O segundo usa portas mais gerais de dois qubit.
- O terceiro, portas de três qubits, onde os qubits ancilla adicionais permitem operações não lineares. Parâmetros reais e complexos foram comparados.

# Resultados

**Table 1.** Computational complexity of hierarchical quantum classifiers under different data encoding

Dimension	Classifier	Qubit encoding	Amplitude encoding
D	TTN	$O(N\chi^5)$	$O(N\chi^{N+5})$
	MERA	$O(N^{6\log_2\chi}\chi^4)$	$O(N^{6\log_2\chi}\chi^{N+4})$
2D	TTN	$O(N^2\chi^5)$	$O(N^2\chi^{2N+5})$
	MERA	$O(\chi^{11N-16})$	$O(\chi^{13N-16})$

The complexities indicate the number of multiplications of scalar numbers required to obtain the measurement outcomes. We use  $N\chi$ -dimensional qudits in one dimension and  $N \times N\chi$ -dimensional qudits in two dimensions

# Resultados

Table 2. Binary classification accuracy on the Iris dataset					
Classifier	Unitaries	Rotations	1 or 2	2 or 3	1 or 3
TTN	Simple	Real	100.00 $\pm$ 0.00	96.77 $\pm$ 0.00	100.00 $\pm$ 0.00
Mean test accuracy and one standard deviation are reported for TTN classifiers with five different random parameter initializations. The Iris dataset consists of three classes. From these we constructed three binary classification tasks					

# Resultados

**Table 3.** Binary classification accuracy on the MNIST dataset

Classifier	Unitaries	Rotations	Is > 4	Is even	0 or 1	2 or 7
TTN	Simple	Real	$65.59 \pm 0.57$	$72.17 \pm 0.89$	$92.12 \pm 2.17$	$68.07 \pm 2.42$
TTN	General	Real	$74.89 \pm 0.95$	$83.13 \pm 1.08$	$99.79 \pm 0.02$	$97.64 \pm 1.60$
MERA	General	Real	$75.20 \pm 1.51$	$82.83 \pm 1.19$	$99.84 \pm 0.06$	$98.02 \pm 1.40$
Hybrid	General	Real	$76.30 \pm 1.04$	$83.53 \pm 0.21$	<b><math>99.87 \pm 0.02</math></b>	$98.07 \pm 1.46$
TTN	Simple	Complex	$70.90 \pm 0.73$	$80.12 \pm 0.64$	$99.37 \pm 0.12$	$94.09 \pm 3.37$
TTN	General	Complex	$77.56 \pm 0.45$	$83.53 \pm 0.69$	$99.77 \pm 0.02$	$97.63 \pm 1.48$
MERA	General	Complex	<b><math>79.10 \pm 0.90</math></b>	<b><math>84.85 \pm 0.20</math></b>	$99.74 \pm 0.02$	<b><math>98.86 \pm 0.07</math></b>
Hybrid	General	Complex	$78.36 \pm 0.45$	$84.38 \pm 0.28$	$99.78 \pm 0.02$	$98.46 \pm 0.19$
Logistic	N/A	N/A	$70.70 \pm 0.01$	$81.72 \pm 0.01$	$99.53 \pm 0.01$	$96.17 \pm 0.01$

Mean test accuracy and one standard deviation are reported for TTN, MERA, and hybrid classifiers with five different random initial parameter settings using two different types of unitary parametrization. Hybrid classifiers consist of pre-training a TTN classifier and then transforming it into a MERA classifier by training additional unitaries. Bold values indicate the best result for each classification task

# Resultados

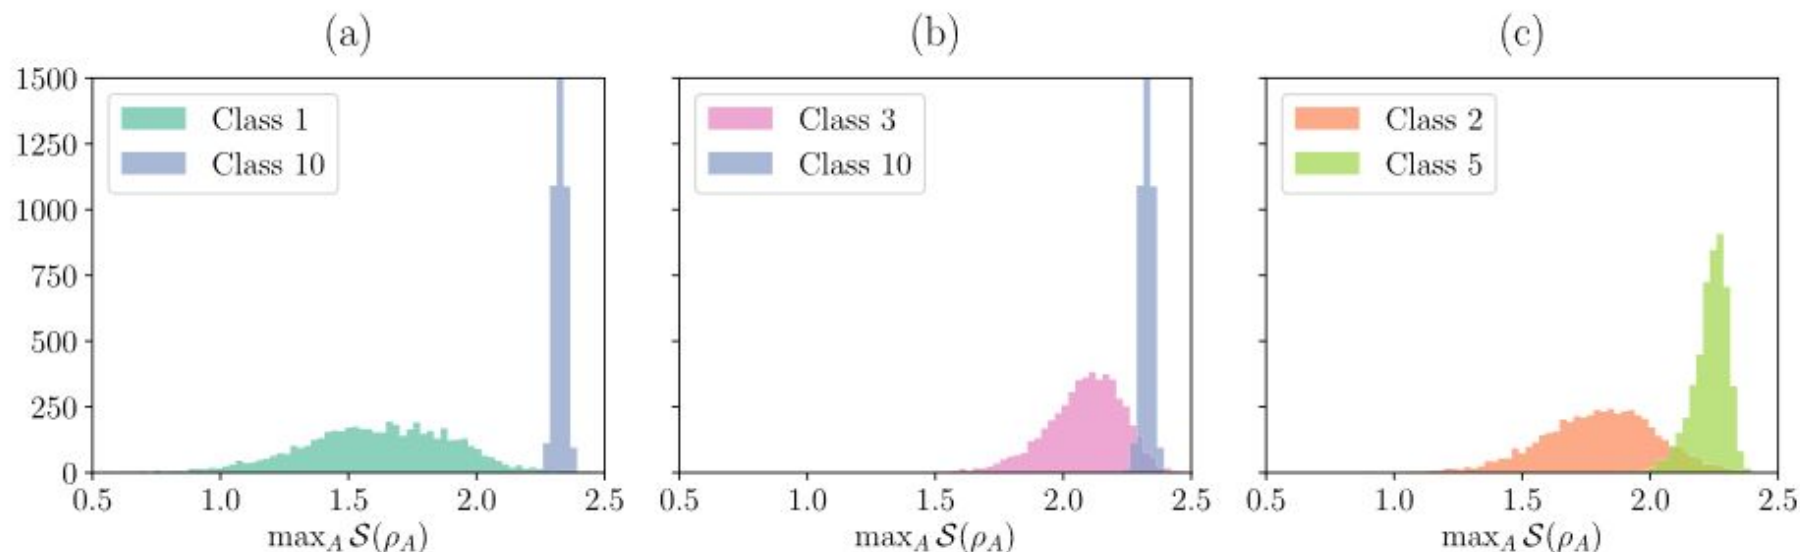


Figura 5: Distribuição bimodal da entropia máxima de entrelaçamento para conjuntos de dados quânticos sintéticos.

# Resultados

A base de dados quântica foi gerada por circuitos randômicos com diferentes números de blocos de construção. A partir desses dados, os pesquisadores criaram 3 cenários de classificação. Fig 5.a. 1 vs 10, b. 3 vs 10 e c. 2 vs 5.

Os sub-gráficos mostram histogramas de entropia máxima de entrelaçamento bimodais para os três cenários de classificação.

Essa propriedade pode ser usada para separar classes e classificar dados com alta precisão, portanto, os tipos de classificação sintéticas são bem colocados.

# Resultados

**Table 4.** Binary classification test accuracy on synthetic quantum datasets

Classifier	1 or 10	3 or 10	2 or 5
TTN (Universal gates)	50.25 $\pm$ 0.58	49.95 $\pm$ 0.72	50.36 $\pm$ 1.05
TTN (Ancilla gates)	64.0 $\pm$ 01.12	59.33 $\pm$ 0.22	58.02 $\pm$ 0.65

Mean test accuracy and one standard deviation are reported for TTN classifiers with five different random initial parameter settings using two different types of unitary parametrization. Bold values indicate the best result for each classification task

# Resultados




Figura 6: Efeito do ruído despolarizante e do ruído de amostragem finito na precisão do classificador TTN na base de dados da Iris.



# Resultados

Apresentaram média e um desvio padrão da precisão da classificação calculada no conjunto de testes.

A precisão média permanece acima de 95% para o ruído despolarizante até  $\lambda = 0,07$ , mostrando algum nível de resiliência no modelo.

À medida que aumentaram ainda mais o ruído despolarizante, (i) o modelo piora e a precisão média diminui, e (ii) o desvio padrão aumenta, indicando a necessidade de mais medições para superar o ruído de amostragem finito

# Resultados




Figura 7: Esquema do circuito do classificador TTN utilizado na base de dados Iris. O classificador TTN usa parametrização unitária simples com rotações reais. Foi treinado classicamente e, em seguida, implementado no computador quântico ibmqx4.

# Conclusão

Em todas as experiências, descobriram que o MERA 1D supera o TTN 1D, sugerindo que o MERA 2D poderia, em princípio, superar o TTN 2D.

Tal hipótese deve ser testada em experimentos futuros, à medida que computadores quânticos apropriadamente grandes se tornem disponíveis.